

문맥 불일치 메시지 사전 경고 시스템

 career-jikimi

그 작은 실수로부터,
당신의 사회생활을 지켜드리겠습니다.

Bomb-pod · 팀장 김지환 · 팀원 김연희 · 2026. 08. 04



이 방에 맞지 않는 것 같습니다.
그래도 보낼까요?

취소

보내기

목차

01 서론

- 개발 배경
- 서비스 소개 · 시연
- WBS · 역할 분담

02 본론

- 아키텍처 / 기술스택
- AI 모델링 전체 흐름
- ① 모델 · ② 데이터 · ③ 평가

03 결론

- 성과 정리
- 고도화 계획
- Q & A

01 · 서론

기획 배경

1

문제
부담이 큰 사회적 비용

업무방에 잘못 보내는 개인 메시지 — 한 번의 실수로도
곤란해집니다.

2

기존 대안의 한계
전송 취소, 답이 아니다

상대가 확인한 뒤에는 취소도 소용없습니다.


3

우리의 접근
사전 차단!

문맥을 분석해 어울리지 않는 메시지를 전송 전에 차단합니다.

01 · 서론

서비스 소개 · 시연



1

채팅어플 구현

기능 개발을 위해 WebSocket을 활용한 채팅어플을 구현했습니다.

2

전송 전 문맥 판정

최근 대화 10개와 보낼 문장을 함께 읽어 판정하고, 부적절하면 전송하지 않고 되웁니다.

3

선택의 기록

경고 이후 보냈는지 취소했는지를 기록 — 사실상의 정답 라벨로 다음 평가 데이터가 됩니다.

채팅

test1

+ 새 채팅방

발

발표 준비방

오후 2:25

팀원 1

발

발표 준비

오후 2:24

팀원

발

발표 자료 준비

오후 12:46

팀원

테

테스트방

오후 12:33

test12345

발

발표

오후 12:27

팀원 1

발

발표 준비

오전 10:40

팀원

동

동네 풋살

오전 10:02

도현이 형, 태현 (동아리), 지우 (헬스)

엄

엄마

오전 9:52

2명

오

OO물산 PoC

오전 9:40

서연 팀장님, 하늘 매니저님

헬

헬스 메이트

오전 9:28

태현 (동아리), 지우 (헬스)

서

서연 팀장님

오전 9:17

2명


수

수민 동기

오전 9:05

1명


WBS



02 · 본론

아키텍처 / 기술스택

컨테이너 3개



판정 백엔드 (교체 가능)

encoder ← 현재
로컬openai
GPT APIollama
로컬 LLM

프론트엔드

React 18 · TypeScript
5.7
Vite 6 · Zustand

백엔드

FastAPI · WebSocket
SQLAlchemy + asyncmy

데이터

MariaDB 11 (InnoDB)
Alembic 마이그레이션

AI 판정

A.X-Encoder 파인튜닝
PyTorch (CPU)

배포 · 시험

Docker Compose ·
nginx
pytest 355 · Vitest 147

AI 모델링 전체 흐름



모델 선정

skt / A.X-Encoder-base

ModernBERT 계열 인코더 · 0.1B · Apache-2.0

파라미터	약 1억
모델 크기	299 MB
구조	cross-encoder 이진 분류

두 가지를 같은 조건에서 비교했습니다

GPT API 성능 좋음 · 대화가 외부로 나감 · 비용 · 1340.4ms

인코더 (채택) 성능 개선 가능 · 외부 전송 없음 · 비용X · 538ms

1

생성이 아닌 분류

필요한 출력은 '적절 / 부적절' 하나뿐이다.
문장을 만들 필요가 없으니 디코더가 필요 없다.

2

외부 유출 X

전량 로컬에서 처리한다. 채팅 내용을 외부 API로 보내지 않는 것이 이 서비스에서는 기능 요건이다.

3

비용 X, 속도↑

538ms — 타임아웃 예산 4초에 여유가 크다.
호출 비용이 없어 판정을 아끼지 않아도 된다.

02 · 본론 · AI 모델링 ②

학습 데이터 제작

1 초기 데이터의 문제

초기 데이터는 ‘공격적·비난’은 항상 부적절,
‘정보·조언 제공’은 항상 적절처럼
scenario만으로 라벨이 결정되는 구조였습니다.

문제 scenario 기반 라벨 누출로 문맥 관계를
학습하지 않을 가능성

2 짝 구조로 재설계

동일한 response에 적절한 history와 부적절한
history를 각각 배치했습니다.

구조 같은 응답+ 서로 다른 대화 2개
적절 1개 + 부적절 1개

3 누출 재검증 (최종)

문맥을 파악하여 판단한다는 결과값 도출

결과 response-only 0.391 · history-only
0.294 · 중복 0건

핵심 결론 같은 응답을 서로 다른 문맥에 배치해, 문장 자체가 아닌 문맥과 응답의 관계를 학습하도록 설계했습니다.

02 · 본론 · AI 모델링 ②

딱 구조 — 같은 문장, 다른 방



학습 데이터의 고유 응답 500개 전원이 이렇게 양쪽 라벨로 등장합니다.

학습 세팅

MAX_LEN

384

실측 토큰 최대 117 — 전량 수용

BATCH

8

T4 메모리 기준 현실적 상한

LR

 $5e-5$

BERT 파인튜닝 표준 범위 상단

EPOCHS

4

16 epoch 계측으로 확인

Loss · Optimizer

Loss CrossEntropyLoss (num_labels=2)**Optimizer** AdamW · weight_decay 0.01**Scheduler** linear + warmup 10%**Grad clip** 1.0


분할 전략

StratifiedGroupKFold(5) · 그룹 = pair_id

같은 짝이 학습과 검증에 갈라지지 않게 묶었습니다. 짝의 반쪽을 본 모델이 나머지 반쪽을 맞히면 점수가 부풀러지기 때문입니다.

02 · 본론 · AI 모델링 ③

모델 학습량(epoch) 결정



조건

총 검증 epoch = 16

검증 step = 25

결론

epoch 4 선택

검증 loss 최저 = epoch 4 (0.358)

epoch 4 이후 => 과적합으로 판단

모델 학습 평가

Q1

성능이 나오는가

5-fold 교차검증 OOF 정확도

0.854

기준: 찍기 수준 0.5

Q2

문맥을 읽었는가

절제 실험 — 문맥 교체·삭제 후 재 판정

-0.385

찍기 수준 아래로 무너짐

Q3

운영값은 어디인가


threshold 스윙 —
precision/recall/팝업률

0.7 채택

F1 최대점 대신 precision 우선

02 · 본론 · AI 모델링 ③

절제 실험 — 문맥 의존성 검증



무엇을 한 실험인가

보낼 메시지는 하나도 바꾸지 않고, 앞 대화만 다른 방의 것으로 바꿔치기하거나 아예 지운 뒤 같은 모델로 다시 판정했습니다.


결론

**문맥을 건드리면 찍기 수준으로
무너진다**

응답은 그대로인데 성능이 사라졌습니다. 모델이 말투가 아닌 대화 문맥을 근거로 판단했다는 증거입니다.

02 · 본론 · AI 모델링 ③

기준선 대조와 운영 임계값



운영 임계값 — 0.7 채택

임계값	precision	recall	팝업률
0.50 (F1 최대)	0.850	0.860	0.506
0.70 (채택)	0.882	0.776	0.440
0.85	0.921	0.582	0.316

03 · 결론

성과 정리

0.854

교차검증 OOF 정확도

규칙 기반 0.725 대비 +0.129

-0.385

문맥 절제 시 하락폭

문맥을 읽는다는 직접 증거

538ms

판정 지연

타임아웃 예산 4초의 13%

0건

외부 전송

대화가 서버 밖으로 안 나감

✓ 채팅 웹앱

회원·친구·방·실시간 전송 · 판정 팝업

✓ 데이터셋

학습 1,000 + 평가 100 · 누출 전 항목
통과

✓ 판정 모델

A.X-Encoder · 백엔드 3종 교체 구조

✓ 시험

백엔드 355 · 프론트 147 · 전부 통과

※ 정확도·하락폭은 5-fold OOF 기준 · 지연은 단일 요청 순차 30회 실측 (배치 32 처리량 p50 512ms)

03 · 결론

현재 한계와 대응전략

1 초기 대화 보호 공백

대화가 10개 이상 쌓여야 AI 검증이 시작되어, 신규 채팅방·새 프로젝트 초반에는 사전 경고를 제공하지 못합니다.

대응 채널명·채팅방 목적·초기 안내 문구를 초기 문맥으로 활용해 판정 시작 시점을 앞당김

2 세부 문맥 탐지 한계

다른 방에 보낼 법한 메시지는 탐지하지만, 같은 방 안에서 날짜·시간·대상·조건만 어긋나는 메시지는 판정하지 못합니다.

대응 날짜·시간·인물·수량·조건 중 하나만 어긋난 데이터를 학습에 추가

3 경고 근거 설명 부족

현재는 “이 방에 맞지 않는 것 같습니다”라는 판정 결과만 제공하며, 어떤 내용이 앞선 대화와 충돌했는지는 설명하지 않습니다.

대응 경고 사유 유형과 관련 문맥을 함께 제시하고, 사용자의 선택을 판정 개선에 활용

세 가지 모두 단순한 모델 점수의 문제가 아니라, 현재 서비스를 실제로 운영할 때 발생하는 보호 공백입니다.

03 · 결론

고도화 계획

1

초기 문맥 보완

최우선

채널명·채팅방 목적·초기 안내 문구를 문맥으로 활용해, 대화가 적은 구간에서도 판정할 수 있도록 개선합니다.

2

세부 문맥 데이터 확장

다음

날짜·시간·인물·수량·업무 조건 중 한 요소만 어긋난 Hard 데이터를 학습에 추가해 탐지 범위를 확장합니다.

3

근거가 보이는 경고 제공

다음

단순한 적절·부적절 결과를 넘어, 경고 사유 유형과 관련된 이전 대화를 함께 제시합니다.

4

실사용 검증 체계 구축

다음

누적된 보내기·취소 선택을 분석해 실제 오발송 비율과 오탐 수준을 확인하고, 운영 환경에 맞게 임계값을 재조정합니다.

Q & A

감사합니다

- 팀장 김지환 - 프로젝트 총괄
- 팀원 김연희 - 데이터셋 생성 및 성능 검증